Đặc trưng hành vi theo thời gian hay dữ liệu tổng hợp?

Nghiên cứu thực nghiệm về phát hiện giao dịch rửa tiền trên dữ liệu IBM AML

Đồ án môn học An toàn và Bảo mật Hệ thống Thông tin

Nguyễn Thế Vĩnh*
26848266@grad.uit.edu.vn
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
TP. Hồ Chí Minh, Việt Nam

Hoàng Đức Chung†
26848014@grad.uit.edu.vn
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
TP. Hồ Chí Minh, Việt Nam

Nguyễn Hải Đăng‡
26848027@grad.uit.edu.vn
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
TP. Hồ Chí Minh, Việt Nam

TÓM TẮT

Phát hiện giao dịch rửa tiền bằng học máy gặp hai trở ngại: lớp dương cực hiếm và tín hiệu nằm ở bối cảnh hành vi chứ không ở từng giao dịch đơn lẻ. Bài báo so sánh hai hướng cải thiện trong cùng một quy trình đánh giá trên 5.078.345 giao dịch của bộ dữ liệu mô phỏng IBM AML HI-Small: *tăng lượng dữ liệu* lớp dương bằng lặp mẫu, SMOTENC, CTGAN và mô hình ngôn ngữ lớn (LLM), và *cải thiện biểu diễn* bằng đặc trưng hành vi theo thời gian. Chúng tôi xây dựng 63 đặc trưng về lịch sử tài khoản, hoạt động theo cửa sổ và quan hệ đối tác, được tính nghiêm ngặt chỉ từ các giao dịch xảy ra trước thời điểm dự đoán, và giữ cố định bộ phân loại XGBoost. Bổ sung lần lượt các nhóm đặc trưng nâng Average Precision (AP) từ 0,171 lên 0,534 và 0,684; với 1.000 cảnh báo có điểm cao nhất, cấu hình đầy đủ đạt precision 91,50% và recall 50,89%. Ngược lại, không phương pháp tăng cường dữ liệu nào cải thiện rõ rệt so với không tăng cường; hai biến thể LLM giảm AP từ 0,670 xuống 0,609 và 0,597, và dữ liệu do CTGAN hoặc LLM sinh ra gần như bị phân biệt hoàn toàn với dữ liệu thật (disc-AUC $\geq$ 0,983). Phân tích bổ sung phát hiện phân bố dữ liệu thay đổi mạnh từ ngày 11/09/2022; trên phần test trước mốc này, lợi ích của đặc trưng hành vi vẫn được duy trì. Kết quả cho thấy với dữ liệu giao dịch, chất lượng biểu diễn hành vi và tính đúng đắn theo thời gian của pipeline quan trọng hơn việc bổ sung dữ liệu tổng hợp.

TỪ KHÓA

phát hiện rửa tiền, giám sát giao dịch, XGBoost, đặc trưng thời gian, quan hệ tài khoản, tăng cường dữ liệu, mô hình ngôn ngữ lớn, rò rỉ dữ liệu

1 GIỚI THIỆU

Rửa tiền là quá trình hợp thức hóa nguồn tiền bất hợp pháp thông qua chuỗi giao dịch nhằm che giấu nguồn gốc. Các tổ chức tài chính có nghĩa vụ giám sát giao dịch và báo cáo giao dịch đáng ngờ theo khuyến nghị của FATF [12] và, tại Việt Nam, theo Luật Phòng, chống rửa tiền 2022 [14]. Dưới góc nhìn an toàn hệ thống thông tin, hệ thống giám sát giao dịch đóng vai trò tương tự một hệ thống phát hiện xâm nhập: nó phải xếp hạng một luồng sự kiện rất lớn, trong đó chỉ một tỷ lệ nhỏ là độc hại, và mỗi cảnh báo sai đều tiêu tốn thời gian của chuyên viên điều tra.

Phát hiện rửa tiền bằng học máy gặp ba khó khăn. Thứ nhất, lớp dương cực hiếm: trong bộ dữ liệu IBM AML HI-Small [3] chỉ khoảng 0,1% giao dịch được gán nhãn rửa tiền. Thứ hai, một giao dịch đơn lẻ hầu như không mang tín hiệu; dấu hiệu nằm ở *bối cảnh* như lịch sử tài khoản, nhịp độ giao dịch và mối quan hệ giữa các tài khoản. Thứ ba, dữ liệu có thứ tự thời gian, nên rất dễ vô tình để mô hình "nhìn thấy tương lai" khi xây dựng đặc trưng, dẫn tới kết quả lạc quan giả tạo.

Có hai hướng phổ biến để cải thiện bộ phát hiện. Hướng thứ nhất *tăng lượng dữ liệu* lớp dương bằng lấy mẫu lại, SMOTE [6], mô hình sinh như CTGAN [18], hoặc gần đây là mô hình ngôn ngữ lớn (LLM) [5, 15]. Hướng thứ hai *cải thiện biểu diễn* bằng đặc trưng mô tả hành vi theo thời gian của tài khoản và quan hệ giữa các tài khoản [4, 8]. Bài báo này so sánh hai hướng trên trong cùng một quy trình: cùng cách chia dữ liệu theo thời gian, cùng bộ phân loại XGBoost [7] với siêu tham số cố định, cùng cách chọn ngưỡng trên tập validation và ba seed. Các đóng góp chính gồm:

- Một bộ 63 đặc trưng hành vi được tính *nghiêm ngặt theo thời gian*: chỉ dùng giao dịch có thời điểm nhỏ hơn thời điểm dự đoán, các giao dịch cùng phút dùng chung một ảnh chụp lịch sử, và tổng tiền được tách theo tiền tệ.
- Một phép phân rã có kiểm soát gồm năm cấu hình đặc trưng định trước, cho thấy AP tăng từ 0,171 lên 0,684 và mọi bước bổ sung đều cải thiện AP trong cả ba seed.
- Đánh giá bốn phương pháp tăng cường dữ liệu, gồm hai biến thể sinh dữ liệu bằng LLM, kèm chẩn đoán chất lượng dữ liệu sinh. Không phương pháp nào cải thiện rõ rệt; dữ liệu CTGAN và LLM gần như bị tách biệt hoàn toàn khỏi dữ liệu thật.
- Phân tích tính hợp lệ của phép đánh giá: chính sách thời gian, sự thay đổi phân bố từ ngày 11/09/2022 và việc tái sử dụng tập test, cùng quy trình xác minh kết quả có thể tái lập.

2 CÔNG TRÌNH LIÊN QUAN

Dữ liệu và benchmark. Do dữ liệu ngân hàng thật không thể công bố, nghiên cứu học thuật chủ yếu dùng dữ liệu công khai như đồ thị giao dịch Bitcoin Elliptic [17] hoặc dữ liệu mô phỏng. Altman và cộng sự [3] công bố trình sinh AMLworld dựa trên mô phỏng tác nhân và sáu bộ dữ liệu giao dịch ngân hàng tổng hợp có nhãn đầy đủ [2]; HI-Small là bộ nhỏ nhất với tỷ lệ giao dịch rửa tiền cao hơn.

Đặc trưng đồ thị và GNN. Graph Feature Preprocessor (GFP) [4], thuộc thư viện Snap ML [9], trích xuất theo thời gian thực các mẫu fan-in/out, scatter-gather và chu trình, cùng thống kê đỉnh trong

*Mã số học viên: 26848266.
†Mã số học viên: 26848014.
‡Mã số học viên: 26848027.

Bảng 1: Chia dữ liệu theo thời gian.

Tập	Giao dịch	Rửa tiền	Tỷ lệ	Khoảng thời gian
Train	3.046.861	2.297	0,075%	01/09 – 06/09 13:35
Validation	1.015.602	1.082	0,107%	06/09 13:36 – 08/09 16:11
Test	1.015.882	1.798	0,177%	08/09 16:12 – 18/09

cửa sổ thời gian, rồi đưa vào mô hình gradient boosting; trên HI-Small cách làm này đạt F1 lớp dương khoảng 0,63–0,65 và vượt các GNN tiêu chuẩn. Multi-GNN [11] mở rộng GNN cho đa đồ thị có hướng. Deprez và cộng sự [8] tổng quan 97 công trình và cho thấy thông tin mạng lưới cải thiện khả năng dự đoán. Các công trình gần đây tập trung vào tốc độ khai phá mẫu [19] hoặc biểu diễn đồ thị gần-thời-gian [16]. Ngược lại, Effendi và Chattopadhyay [10] ghi nhận XGBoost có thể không cần đặc trưng đồ thị trong một số cấu hình dữ liệu. Bài báo này không tái hiện GFP mà tập trung vào các thống kê hành vi và quan hệ cục bộ có thể giải thích trực tiếp.

Tăng cường dữ liệu và LLM. SMOTE [6] nội suy giữa các mẫu thiểu số; CTGAN [18] học phân phối dữ liệu bảng bằng GAN có điều kiện. LLM được dùng để sinh dữ liệu bảng [5], kết hợp với lọc dữ liệu trong chế độ ít mẫu [15], hoặc để tự động đề xuất đặc trưng [1, 13]. Chúng tôi đánh giá khả năng sinh giao dịch rửa tiền bằng LLM trong không gian đặc trưng cho bài toán cực kỳ mất cân bằng.

3 DỮ LIỆU VÀ BÀI TOÁN

Bộ dữ liệu. Chúng tôi dùng tệp `HI-Small_Trans.csv` của IBM AML [2] gồm 5.078.345 giao dịch trong khoảng 01–18/09/2022, trong đó 5.177 giao dịch (0,102%) được gán nhãn rửa tiền. Mỗi giao dịch có thời điểm (độ phân giải phút), ngân hàng và tài khoản gửi/nhận, số tiền và tiền tệ hai phía, hình thức thanh toán và nhãn. Tệp được đối chiếu bằng mã băm SHA-256 giữa môi trường cục bộ và Kaggle. Tài khoản được định danh bằng cặp ngân hàng–mã tài khoản; định danh chỉ dùng để tra cứu lịch sử, không đưa vào mô hình.

Bài toán. Mỗi giao dịch là một mẫu. Mô hình trả về điểm nghi ngờ để xếp hạng; quyết định nhị phân dùng ngưỡng chọn trên validation. Điểm không được hiệu chuẩn thành xác suất rủi ro.

Chia dữ liệu theo thời gian. Dữ liệu được sắp xếp theo thời điểm và chia xấp xỉ 60/20/20; mốc cắt được dịch về đầu nhóm giao dịch cùng phút để một phút không bị tách sang hai tập (Bảng 1). Không xáo trộn dữ liệu; nhãn của validation và test không tham gia xây dựng đặc trưng hay huấn luyện.

4 PHƯƠNG PHÁP

4.1 Chính sách thời gian

Gọi t là thời điểm của giao dịch cần dự đoán. Tập lịch sử được phép quan sát là

$$H(t) = \{\, j : t_j < t \,\}. \tag{1}$$

Vì dữ liệu chỉ chính xác đến phút và thứ tự thật trong cùng phút là không biết, mọi giao dịch cùng thời điểm dùng chung một ảnh chụp lịch sử; lịch sử chỉ được cập nhật sau khi cả nhóm đã được truy vấn. Nhờ vậy đặc trưng không phụ thuộc thứ tự dòng trong tệp. Giao dịch tự chuyển tạo một sự kiện gửi và một sự kiện nhận, và sự kiện gửi của chính giao dịch không trở thành lịch sử của phía nhận. Cửa sổ độ dài W được định nghĩa là $[t - W, t)$. Các giao dịch không nhãn đã xảy ra trong validation và test được phép bổ sung lịch sử cho giao dịch đến sau, tương ứng với việc quan sát luồng giao dịch theo thời gian.

4.2 Đặc trưng hành vi

Bộ đặc trưng gồm bốn nhóm, tổng cộng 63 cột:

- **Giao dịch (11):** log số tiền gửi/nhận, giờ, thứ, hình thức thanh toán, tiền tệ hai phía, cùng ngân hàng, tự chuyển, đổi tiền tệ, số tiền tròn trăm.
- **Lịch sử (17):** với mỗi tài khoản gửi và nhận: số giao dịch trước đó, số lượt gửi và nhận, trung bình log số tiền gửi và nhận, thời gian từ giao dịch gần nhất, số giao dịch cùng ngày tổng và theo hướng; thêm số giao dịch trước đó của cặp gửi→nhận.
- **Hoạt động (20):** với cửa sổ 1 giờ và 24 giờ, số lượt và log tổng tiền theo hướng của mỗi tài khoản, cùng độ lệch giữa log số tiền hiện tại và trung bình log lịch sử cùng hướng. Tổng tiền và độ lệch được tính riêng theo tài khoản *và tiền tệ*, không cộng các đồng tiền khác nhau khi không có tỷ giá. Tổng trượt dùng phép cộng bù sai số Neumaier để không để lại sai số khi các khoản tiền chênh lệch rất lớn rời khỏi cửa sổ.
- **Quan hệ (15):** số đối tác duy nhất theo hướng và cửa sổ, số giao dịch lịch sử của cặp đảo chiều, tuổi và độ gần của quan hệ gửi→nhận, số giao dịch của cặp trong cửa sổ, và tỷ trọng đối tác trong 24 giờ (số giao dịch A→B chia số lượt gửi của A).

Khi không có lịch sử, số đếm và tổng bằng 0, còn trung bình và khoảng thời gian để trống (NaN) cho XGBoost tự xử lý. Năm cấu hình được xác định trước khi chạy: F0 = giao dịch; F1 = F0 + lịch sử; F2 = F1 + hoạt động; F3 = F1 + quan hệ; F4 = F1 + hoạt động + quan hệ. Hiệu số F1−F0 đo tác động của lịch sử; F2−F1 và F3−F1 đo lợi ích của từng nhóm khi đã có lịch sử; F4−F2 và F4−F3 đo phần bổ sung của nhóm còn lại. Đặc trưng được tính bằng các phép quét tuyến tính theo tài khoản, tăng tốc bằng Numba.

4.3 Tăng cường dữ liệu

Các phương pháp tăng cường chỉ bổ sung giao dịch rửa tiền tổng hợp vào tập train; validation và test luôn là dữ liệu thật. Số mẫu bổ sung bằng 0,5 lần số mẫu dương của train (1.148 mẫu mỗi lượt). Chúng tôi so sánh: **ER** lặp ngẫu nhiên mẫu dương; **E1** SMOTENC trên đặc trưng đã chuẩn hóa, cột phân loại lấy mode của láng giềng; **E2** CTGAN 300 epoch chỉ học trên mẫu dương; **E3a/E3b** một LLM thương mại qua OpenAI API sinh giao dịch rửa tiền dạng JSON từ ví dụ thật, thống kê cột và các ràng buộc logic giữa các cột, trong đó E3b bổ sung mô tả các kiểu rửa tiền của AMLworld vào prompt. Dữ liệu LLM được kiểm tra hợp lệ, loại trùng lặp và loại các dòng sao chép nguyên văn dữ liệu thật; chi phí gọi API được giới hạn bằng một sổ ngân sách. Chất lượng dữ liệu sinh được đo bằng thống kê KS trung bình theo cột so với mẫu dương thật, và bằng AUC của một bộ phân loại XGBoost phân biệt thật/giả (*disc-AUC*; 0,5 nghĩa là không phân biệt được).

Thí nghiệm tăng cường được thực hiện trước nghiên cứu đặc trưng, trên pipeline 28 đặc trưng tương ứng F1 nhưng xử lý các giao dịch cùng phút theo thứ tự dòng ổn định trong tệp. Vì khác giao thức, chúng tôi chỉ so sánh các phương pháp tăng cường với nhau, không so sánh con số tuyệt đối với F0–F4.

4.4 Mô hình và đánh giá

Mọi cấu hình dùng XGBoost với tối đa 1.000 cây, learning rate 0,05, độ sâu 8, subsample và colsample 0,8, trọng số nút con tối thiểu 1, thuật toán `hist` trên GPU, dừng sớm sau 100 vòng theo AUC-PR trên validation. Không tìm siêu tham số riêng cho từng cấu hình và không thay đổi tỷ lệ lớp. Ngưỡng tối đa F1 được chọn trên validation của từng lượt chạy rồi áp dụng nguyên cho test.

Chỉ số chính là Average Precision (AP), tính bằng hàm average precision của scikit-learn. Ngoài ra chúng tôi báo cáo F1 tại ngưỡng và Precision@1000/Recall@1000: tỷ lệ giao dịch rửa tiền trong 1.000 cảnh báo có điểm cao nhất trên toàn tập test, và tỷ lệ giao dịch rửa tiền của test nằm trong danh sách đó. Accuracy không được dùng vì lớp dương rất hiếm. Mỗi cấu hình chạy ba seed (0, 1, 2); bảng trình bày trung bình ± độ lệch chuẩn mẫu, và các so sánh dùng hiệu số theo cùng seed. Độ lệch chuẩn này phản ánh biến động huấn luyện trên cùng tập test, không phải khoảng tin cậy trên quần thể giao dịch mới.

4.5 Xác minh và tái lập

Pipeline có 43 kiểm thử hồi quy: biên thời gian và cửa sổ, giao dịch tự chuyển, tiền tệ, bất biến khi đổi thứ tự các dòng cùng thời điểm, độc lập với nhãn và tương lai, và đối chiếu với cách tính trực tiếp trên mẫu nhỏ. Sau khi chạy, 30 tệp dự đoán của 15 lượt được kiểm tra lại về nhãn, thứ tự, AP, chỉ số tại ngưỡng và việc ngưỡng được chọn trên validation. Một manifest ghi mã băm dữ liệu, mã băm mã nguồn, phiên bản thư viện, danh sách cột và thông tin chia tập. Các lượt chạy được thực hiện trên notebook Kaggle riêng tư với hai GPU Tesla T4, NumPy 2.2.6, pandas 2.3.3, scikit-learn 1.7.2, XGBoost 3.1.1 và Numba 0.61.2.

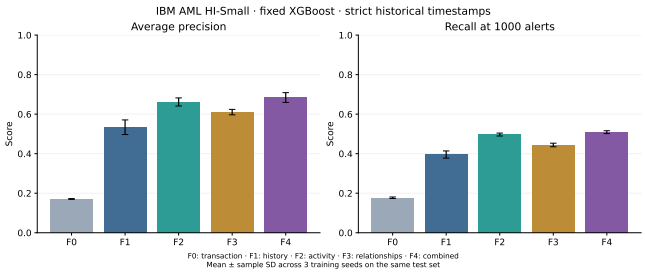
5 KẾT QUẢ THỰC NGHIỆM

5.1 Đóng góp của các nhóm đặc trưng

Bảng 2 cho thấy chỉ dùng thuộc tính của từng giao dịch (F0) cho AP 0,171. Bổ sung lịch sử tài khoản (F1) tạo bước nhảy lớn nhất, lên 0,534. Khi đã có lịch sử, nhóm hoạt động theo cửa sổ (F2, 0,662) đóng góp nhiều hơn nhóm quan hệ (F3, 0,610), và kết hợp cả hai (F4) đạt AP cao nhất, 0,684. Thứ tự các cấu hình giống nhau trên validation và test. Bảng 3 cho thấy mọi bước bổ sung đều cải thiện AP trong cả ba seed, kể cả F4 so với F2: nhóm quan hệ vẫn mang thông tin bổ sung khi đã có nhóm hoạt động. Ba seed chỉ đủ mô tả tính nhất quán của các lượt chạy này, chưa đủ để khẳng định ý nghĩa thống kê.

5.2 Ý nghĩa theo ngân sách cảnh báo

Tập test có 1.798 giao dịch rửa tiền. Trong 1.000 cảnh báo có điểm cao nhất, F1 tìm được trung bình khoảng 712 giao dịch rửa tiền, còn F4 tìm được 915; số cảnh báo sai giảm tương ứng trong khi khối lượng công việc của chuyên viên vẫn là 1.000 cảnh báo. Tuy vậy, recall 0,509 cũng có nghĩa là gần một nửa số giao dịch rửa tiền nằm ngoài danh sách. Ngân sách 1.000 cảnh báo cho toàn tập test là một giả định thực nghiệm; hệ thống thật có thể cần giới hạn theo ngày hoặc theo năng lực xử lý của bộ phận điều tra.



Hình 1: AP và Recall@1000 của năm cấu hình đặc trưng; thanh sai số là độ lệch chuẩn qua ba seed trên cùng tập test.

5.3 Đặc trưng được mô hình sử dụng

Bảng 4 cho thấy các đặc trưng quan trọng nhất kết hợp thuộc tính hiện tại với bối cảnh tài khoản: số lượt nhận trước đó của bên gửi, thời gian từ giao dịch gần nhất của bên nhận, độ lệch số tiền so với lịch sử cùng tiền tệ, hình thức thanh toán và số lần cặp tài khoản đã giao dịch. Điều này phù hợp với trực giác nghiệp vụ: tài khoản vừa nhận tiền rồi chuyển đi với số tiền bất thường so với thói quen là dấu hiệu của tài khoản trung gian. Tuy nhiên, importance của cây bị ảnh hưởng bởi tương quan giữa các cột, nên không được diễn giải như tác động nhân quả và không thay thế phép phân rã theo nhóm ở trên.

5.4 Tăng cường dữ liệu

Bảng 5 cho thấy không phương pháp tăng cường nào cải thiện rõ rệt so với không tăng cường (AP 0,670). SMOTENC cho AP 0,673, chênh lệch theo cùng seed chỉ 0,0026 và nằm trong biến động giữa các seed. Lặp mẫu dương giảm nhẹ (ΔAP = −0,0077), CTGAN giảm −0,0221, còn hai biến thể LLM giảm mạnh nhất (−0,0611 và −0,0732).

Cột disc-AUC giải thích hiện tượng này. Mẫu lặp lại không phân biệt được với mẫu thật (0,502), SMOTENC ở mức 0,647, trong khi CTGAN (0,999) và LLM (0,983 và 0,996) gần như bị tách biệt hoàn toàn. Mẫu giả vẫn mang nhãn dương, nên mô hình học thêm những vùng không tồn tại trong dữ liệu thật. Với LLM, precision tại ngưỡng tăng nhưng recall giảm mạnh: mô hình trở nên "thận trọng" hơn và bỏ sót nhiều giao dịch rửa tiền hơn. Đáng chú ý, bổ sung tri thức miền về các kiểu rửa tiền vào prompt (E3b) không cải thiện mà còn làm kết quả kém ổn định hơn giữa các seed (độ lệch chuẩn F1 lớn). Với dữ liệu giao dịch, mỗi giao dịch rửa tiền là một phần của chuỗi có cấu trúc thời gian và quan hệ; sinh từng dòng độc lập trong không gian đặc trưng khó tái tạo được các ràng buộc này. Đây là lý do thực tế để chúng tôi chuyển trọng tâm sang cải thiện biểu diễn.

5.5 Dịch chuyển phân bố theo thời gian

Thống kê theo ngày cho thấy từ 11/09/2022, lưu lượng giao dịch giảm mạnh trong khi tỷ lệ nhãn dương tăng vọt (Hình 2): ngày 10/09 có 208.325 giao dịch và 442 nhãn dương, ngày 11/09 chỉ có

Bảng 2: Phân rã nhóm đặc trưng hành vi (trung bình ± độ lệch chuẩn qua ba seed). AP được báo cáo trên test và validation; các chỉ số còn lại trên test.

Cấu hình	Số đặc trưng	AP (test)	AP (validation)	F1	Precision@1000	Recall@1000
F0 Giao dịch	11	0,171 ± 0,002	0,064 ± 0,001	0,246 ± 0,016	0,318 ± 0,007	0,177 ± 0,004
F1 +Lịch sử	28	0,534 ± 0,037	0,477 ± 0,026	0,534 ± 0,028	0,712 ± 0,033	0,396 ± 0,018
F2 +Hoạt động	48	0,662 ± 0,020	0,583 ± 0,014	0,664 ± 0,016	0,893 ± 0,013	0,497 ± 0,007
F3 +Quan hệ	43	0,610 ± 0,014	0,521 ± 0,026	0,589 ± 0,026	0,798 ± 0,016	0,444 ± 0,009
F4 Kết hợp	63	**0,684 ± 0,025**	**0,592 ± 0,023**	**0,685 ± 0,026**	**0,915 ± 0,013**	**0,509 ± 0,007**

Bảng 3: Hiệu số AP trên test theo cùng seed.

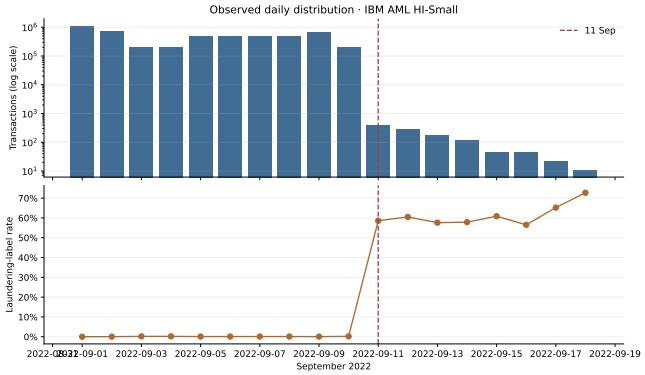
So sánh	ΔAP TB	Độ lệch chuẩn	Số seed tăng
F1 − F0	+0,3631	0,0371	3/3
F2 − F1	+0,1278	0,0165	3/3
F3 − F1	+0,0765	0,0233	3/3
F4 − F1	+0,1502	0,0122	3/3
F4 − F2	+0,0224	0,0043	3/3
F4 − F3	+0,0737	0,0112	3/3

Bảng 4: Mười đặc trưng có tỷ trọng total gain trung bình cao nhất trong F4 (ba seed).

#	Đặc trưng	Nhóm	Gain (%)
1	Số lượt nhận trước đó của bên gửi	Lịch sử	7,74
2	Thời gian từ giao dịch gần nhất của bên nhận	Lịch sử	7,05
3	Độ lệch số tiền so với lịch sử gửi (cùng tiền tệ)	Hoạt động	6,35
4	Hình thức thanh toán	Giao dịch	5,27
5	Giờ trong ngày	Giao dịch	4,77
6	Số giao dịch trước đó của cặp gửi→nhận	Lịch sử	4,64
7	Độ lệch số tiền so với lịch sử nhận của bên gửi	Hoạt động	4,29
8	Độ lệch số tiền so với lịch sử nhận của bên nhận	Hoạt động	3,71
9	Log tổng tiền bên gửi đã nhận trong 24 giờ	Hoạt động	3,70
10	Trung bình log số tiền bên gửi đã nhận	Lịch sử	3,51

396 giao dịch nhưng 232 nhãn dương. Trong tập test, phần trước 11/09 có 1.014.774 giao dịch với 1.143 nhãn dương (0,113%), còn phần từ 11/09 chỉ có 1.108 giao dịch nhưng 655 nhãn dương (59,1%). Nguyên nhân chưa được xác minh từ cơ chế sinh dữ liệu. Đây là phát hiện hậu kiểm, nên chúng tôi không loại phần này khỏi đánh giá chính và không huấn luyện lại, mà tách các dự đoán cố định thành hai phần để chẩn đoán (Bảng 6).

Trên phần trước 11/09, F4 vẫn vượt F1 (AP 0,528 so với 0,333), nên lợi ích của đặc trưng không chỉ đến từ phần cuối bất thường. Ở phần cuối, chỉ thuộc tính giao dịch (F0) đã đạt AP 0,973 và F4



Hình 2: Số giao dịch và tỷ lệ nhãn dương theo ngày trong HI-Small.

không vượt F0. Vì AP phụ thuộc tỷ lệ nhãn, chúng tôi chỉ so sánh các cấu hình trong cùng một phần, không so sánh AP giữa hai phần để kết luận phần nào dễ hơn.

5.6 Chi phí tính toán

Trên Kaggle, tạo toàn bộ bảng đặc trưng (gồm đọc dữ liệu và biên dịch JIT) mất khoảng 35,0 giây và bảng đặc trưng chiếm khoảng 1,33 GB. Huấn luyện 15 mô hình mất 620,2 giây; toàn bộ lượt chạy, gồm đánh giá và ghi tệp, mất 733,3 giây. Các con số mô tả một lượt chạy trên một môi trường cụ thể; chúng tôi chưa đo độ trễ cập nhật đặc trưng theo từng giao dịch trong một dịch vụ trực tuyến.

6 THẢO LUẬN

Ý nghĩa đối với an toàn hệ thống thông tin. Hệ thống giám sát giao dịch là một thành phần phòng thủ; chất lượng của nó được đo bằng số giao dịch rửa tiền tìm được trong ngân sách cảnh báo mà bộ phận điều tra xử lý được. Kết quả cho thấy cách biểu diễn hành vi quyết định hiệu quả nhiều hơn việc bổ sung dữ liệu giả, và các đặc trưng hành vi còn có lợi thế giải thích được bằng ngôn ngữ nghiệp vụ, điều cần thiết khi cảnh báo phải được chuyên viên xem xét. Mặt khác, một biểu diễn dựa trên hành vi cũng tạo ra bề mặt tấn công: kẻ rửa tiền có thể chủ động chia nhỏ giao dịch, giãn thời gian hoặc thêm tài khoản trung gian để làm sai lệch các thống kê theo cửa sổ và quan hệ. Trong triển khai, hệ thống còn cần kiểm soát truy cập dữ liệu, bảo vệ khóa dịch vụ và kết quả cảnh báo; mã nguồn công bố của chúng tôi không chứa khóa API, dữ liệu thô hay dự đoán từng giao dịch.

Bảng 5: Tăng cường dữ liệu train (giao thức pipeline trước, 28 đặc trưng; ba seed). KS và disc-AUC đo khoảng cách giữa mẫu sinh và mẫu rửa tiền thật; disc-AUC càng gần 0,5 thì mẫu sinh càng giống thật.

Phương pháp	AP	F1	Precision@1000	KS trung bình	disc-AUC
E0 Không tăng cường	0,670 ± 0,008	0,673 ± 0,010	0,902	–	–
ER Lặp mẫu dương	0,662 ± 0,010	0,664 ± 0,003	0,894	0,019	0,502
E1 SMOTENC	0,673 ± 0,014	0,674 ± 0,009	0,899	0,047	0,647
E2 CTGAN	0,648 ± 0,014	0,625 ± 0,016	0,883	0,221	0,999
E3a LLM, prompt cơ bản	0,609 ± 0,015	0,588 ± 0,018	0,854	0,126	0,983
E3b LLM, prompt có tri thức AML	0,597 ± 0,051	0,493 ± 0,181	0,838	0,139	0,996

Bảng 6: AP trên hai phần của tập test, tách tại 11/09/2022 (chẩn đoán hậu kiểm, cùng các mô hình).

Cấu hình	Trước 11/09	Từ 11/09
F0	0,071 ± 0,000	0,973 ± 0,000
F1	0,333 ± 0,042	0,962 ± 0,004
F2	0,506 ± 0,022	0,958 ± 0,005
F3	0,413 ± 0,022	0,962 ± 0,004
F4	0,528 ± 0,028	0,961 ± 0,005

Rò rỉ thời gian là một lỗ hổng phương pháp. Một điểm số cao mất ý nghĩa nếu đặc trưng dùng thông tin tương lai, nhãn của tập đánh giá, hoặc phụ thuộc vào thứ tự dòng tùy ý của tệp. Pipeline tăng cường trước dùng 28 đặc trưng tương ứng F1 nhưng xử lý giao dịch cùng phút theo thứ tự dòng, và đạt AP 0,670 khi không tăng cường; F1 với chính sách nghiêm ngặt chỉ đạt 0,534. Hai pipeline còn khác nhau ở một số chi tiết cài đặt, nên đây không phải phép so sánh có kiểm soát. Tuy nhiên, khoảng cách lớn này gợi ý rằng thông tin về các giao dịch cùng phút và thứ tự của chúng trong tệp có thể làm điểm số tăng đáng kể. Vì vậy, khi so sánh các họ đặc trưng hoặc so sánh với công trình khác, chính sách thời gian phải được cố định và công bố rõ, giống như việc cố định mô hình và cách chia dữ liệu. Cũng vì lý do này, F1 của F4 (0,685) không nên được so sánh trực tiếp với các con số đã công bố trên HI-Small [4], vốn dùng cách chọn ngưỡng và cách xử lý thời gian khác.

Giới hạn. (i) Dữ liệu là mô phỏng, nhãn do trình sinh tạo ra, không có KYC, số dư hay xác minh nguồn tiền thật. (ii) Tập test HI-Small đã được xem trong thí nghiệm tăng cường trước, nên dù năm cấu hình được định trước, kết quả vẫn mang tính thăm dò. (iii) Ba seed chỉ đo biến động huấn luyện, không chứng minh ý nghĩa thống kê trên dữ liệu độc lập. (iv) Siêu tham số cố định, nên kết quả là tác động của đặc trưng dưới một ngân sách huấn luyện, không phải hiệu năng tối đa; một số lượt chạm hoặc gần giới hạn 1.000 cây. (v) Trung bình log số tiền trong nhóm lịch sử vẫn gộp các tiền tệ. (vi) Nhóm quan hệ chỉ gồm thống kê cục bộ, chưa phát hiện chu trình hay chuỗi nhiều bước. (vii) Thí nghiệm tăng cường dùng giao thức khác. (viii) Phần cuối tập test có phân bố bất thường. (ix) Kết quả chưa được kiểm chứng trên các bộ AMLworld khác hay dữ liệu ngân hàng thật.

7 KẾT LUẬN

Trên bộ dữ liệu IBM AML HI-Small, cải thiện biểu diễn hành vi mang lại lợi ích lớn và nhất quán, trong khi bổ sung dữ liệu tổng hợp thì không. Với XGBoost cố định, bổ sung lịch sử tài khoản, hoạt động theo cửa sổ và quan hệ đối tác nâng AP từ 0,171 lên 0,684; trong 1.000 cảnh báo có điểm cao nhất, cấu hình đầy đủ đạt precision 91,50% và recall 50,89%. Nhóm hoạt động đóng góp nhiều hơn nhóm quan hệ khi bổ sung riêng, và nhóm quan hệ vẫn cải thiện thêm khi kết hợp. Lặp mẫu, SMOTENC, CTGAN và hai biến thể LLM đều không cải thiện rõ rệt; dữ liệu do CTGAN và LLM sinh ra gần như bị phân biệt hoàn toàn với dữ liệu thật. Kết quả trên phần test trước 11/09 duy trì lợi ích của đặc trưng, đồng thời phần cuối bất thường nhắc rằng kết luận có thể không đồng nhất ở mọi giai đoạn của dữ liệu.

Các hướng phát triển gồm: so sánh với đặc trưng mẫu đồ thị nhiều bước như GFP dưới cùng chính sách thời gian; phân tích kết quả theo từng kiểu rửa tiền; đánh giá độ bền của mô hình trước các chiến lược né tránh như chia nhỏ giao dịch hay dùng tài khoản trung gian; và kiểm chứng trên các bộ AMLworld khác với một tập đánh giá định trước hoàn toàn mới.

Tái lập. Mã nguồn, cấu hình, kiểm thử và kết quả từng lượt chạy được công bố tại https://github.com/Chung10102004/atbmtt. Dữ liệu thô và dự đoán từng giao dịch không được đưa vào kho mã.

TÀI LIỆU

[1] Nikhil Abhyankar, Parshin Shojaee, and Chandan K. Reddy. 2025. LLM-FE: Automated Feature Engineering for Tabular Data with LLMs as Evolutionary Optimizers. arXiv:2503.14434

[2] Erik Altman. 2023. IBM Transactions for Anti Money Laundering (AML). https://www.kaggle.com/datasets/ealtman2019/ibm-transactions-for-anti-money-laundering-aml. Tệp HI-Small_Trans.csv và HI-Small_Patterns.txt.

[3] Erik Altman, Jovan Blanuša, Luc von Niederäusern, Béni Egressy, Andreea Anghel, and Kubilay Atasu. 2023. Realistic Synthetic Financial Transactions for Anti-Money Laundering Models. In *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track.*

[4] Jovan Blanuša, Maximo Cravero Baraja, Andreea Anghel, Luc von Niederäusern, Erik Altman, Haris Pozidis, and Kubilay Atasu. 2024. Graph Feature Preprocessor: Real-time Subgraph-based Feature Extraction for Financial Crime Detection. In *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF).* https://doi.org/10.1145/3677052.3698674 arXiv:2402.08593.

[5] Vadim Borisov, Kathrin Seßler, Tobias Leemann, Martin Pawelczyk, and Gjergji Kasneci. 2023. Language Models are Realistic Tabular Data Generators. In *International Conference on Learning Representations (ICLR).*

[6] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. 2002. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research* 16 (2002), 321–357.

[7] Tianqi Chen and Carlos Guestrin. 2016. XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.* 785–794. https://doi.org/10.1145/2939672.

2939785

[8] Bruno Deprez, Toon Vanderschueren, Bart Baesens, Tim Verdonck, and Wouter Verbeke. 2024. Network Analytics for Anti-Money Laundering – A Systematic Literature Review and Experimental Evaluation. *INFORMS Journal on Data Science* (2024). https://doi.org/10.1287/ijds.2024.0042 arXiv:2405.19383.

[9] Celestine Dünner, Thomas Parnell, Dimitrios Sarigiannis, Nikolas Ioannou, Andreea Anghel, Gummadi Ravi, Madhusudanan Kandasamy, and Haralampos Pozidis. 2018. Snap ML: A Hierarchical Framework for Machine Learning. In *Advances in Neural Information Processing Systems (NeurIPS)*.

[10] Fabrianne Effendi and Anupam Chattopadhyay. 2024. Privacy-Preserving Graph-Based Machine Learning with Fully Homomorphic Encryption for Collaborative Anti-Money Laundering. arXiv:2411.02926

[11] Béni Egressy, Luc von Niederäusern, Jovan Blanuša, Erik Altman, Roger Wattenhofer, and Kubilay Atasu. 2024. Provably Powerful Graph Neural Networks for Directed Multigraphs. In *Proceedings of the AAAI Conference on Artificial Intelligence*.

[12] Financial Action Task Force. 2012. International Standards on Combating Money Laundering and the Financing of Terrorism & Proliferation – The FATF Recommendations. https://www.fatf-gafi.org/en/publications/Fatfrecommendations/Fatf-recommendations.html. Cập nhật định kỳ.

[13] Noah Hollmann, Samuel Müller, and Frank Hutter. 2023. Large Language Models for Automated Data Science: Introducing CAAFE for Context-Aware Automated Feature Engineering. In *Advances in Neural Information Processing Systems (NeurIPS)*.

[14] Quốc hội nước Cộng hòa Xã hội Chủ nghĩa Việt Nam. 2022. Luật Phòng, chống rửa tiền, số 14/2022/QH15.

[15] Nabeel Seedat, Nicolas Huynh, Boris van Breugel, and Mihaela van der Schaar. 2024. Curated LLM: Synergy of LLMs and Data Curation for Tabular Augmentation in Low-Data Regimes. In *International Conference on Machine Learning (ICML)*.

[16] Haseeb Tariq and Marwan Hassani. 2026. Extracting Money Laundering Transactions from Quasi-Temporal Graph Representation. arXiv:2604.02899

[17] Mark Weber, Giacomo Domeniconi, Jie Chen, Daniel Karl I. Weidele, Claudio Bellei, Tom Robinson, and Charles E. Leiserson. 2019. Anti-Money Laundering in Bitcoin: Experimenting with Graph Convolutional Networks for Financial Forensics. In *KDD Workshop on Anomaly Detection in Finance*.

[18] Lei Xu, Maria Skoularidou, Alfredo Cuesta-Infante, and Kalyan Veeramachaneni. 2019. Modeling Tabular Data using Conditional GAN. In *Advances in Neural Information Processing Systems (NeurIPS)*.

[19] Haojie Ye, Arjun Laxman, Yichao Yuan, Krisztian Flautner, and Nishil Talati. 2026. BlazingAML: High-Throughput Anti-Money Laundering (AML) via Multi-Stage Graph Mining. arXiv:2604.12241