Phát hiện rửa tiền bằng machine learning

Đồ án môn học An toàn và Bảo mật Hệ thống Thông tin

Nguyễn Thế Vĩnh
26848266@grad.uit.edu.vn
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
TP. Hồ Chí Minh, Việt Nam

Hoàng Đức Chung
26848014@grad.uit.edu.vn
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
TP. Hồ Chí Minh, Việt Nam

Nguyễn Hải Đăng
26848027@grad.uit.edu.vn
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
TP. Hồ Chí Minh, Việt Nam

TÓM TẮT

Phát hiện giao dịch rửa tiền bằng machine learning gặp hai trở ngại: positive class cực hiếm và tín hiệu nằm ở bối cảnh hành vi chứ không ở từng giao dịch đơn lẻ. Bài báo so sánh hai hướng cải thiện trong cùng một quy trình evaluation trên 5.078.345 giao dịch của bộ dữ liệu mô phỏng IBM AML HI-Small: *data augmentation* cho positive class bằng random oversampling, SMOTENC, CTGAN và Large Language Model (LLM), và *cải thiện biểu diễn* bằng temporal behavioral feature. Chúng tôi xây dựng 63 feature về lịch sử tài khoản, hoạt động theo time window và quan hệ đối tác, được tính nghiêm ngặt chỉ từ các giao dịch xảy ra trước thời điểm dự đoán, và giữ cố định classifier XGBoost. Bổ sung lần lượt các feature group nâng Average Precision (AP) từ 0,171 lên 0,534 và 0,684; với alert budget 1.000 alert có score cao nhất, cấu hình đầy đủ đạt precision 91,50% và recall 50,89%. Ngược lại, không phương pháp data augmentation nào cải thiện rõ rệt so với không augmentation; hai biến thể LLM giảm AP từ 0,670 xuống 0,609 và 0,597, và synthetic data do CTGAN hoặc LLM sinh ra gần như bị phân biệt hoàn toàn với dữ liệu thật (discriminator AUC $\geq$ 0,983). Phân tích bổ sung phát hiện distribution shift mạnh từ ngày 11/09/2022; trên phần test trước mốc này, lợi ích của behavioral feature vẫn được duy trì. Kết quả cho thấy với dữ liệu giao dịch, chất lượng feature engineering và tính đúng đắn theo thời gian của pipeline quan trọng hơn việc bổ sung synthetic data.

TỪ KHÓA

anti-money laundering, transaction monitoring, XGBoost, temporal feature, feature engineering, data augmentation, Large Language Model, data leakage

1 GIỚI THIỆU

Rửa tiền (money laundering) là quá trình hợp thức hóa nguồn tiền bất hợp pháp thông qua chuỗi giao dịch nhằm che giấu nguồn gốc. Các tổ chức tài chính có nghĩa vụ transaction monitoring và báo cáo giao dịch đáng ngờ theo khuyến nghị của FATF [12] và, tại Việt Nam, theo Luật Phòng, chống rửa tiền 2022 [14]. Dưới góc nhìn an toàn hệ thống thông tin, hệ thống transaction monitoring đóng vai trò tương tự một intrusion detection system: nó phải xếp hạng một luồng sự kiện rất lớn, trong đó chỉ một tỷ lệ nhỏ là độc hại, và mỗi false positive đều tiêu tốn thời gian của chuyên viên điều tra.

Phát hiện rửa tiền bằng machine learning gặp ba khó khăn. Thứ nhất, positive class cực hiếm: trong bộ dữ liệu IBM AML HI-Small [3] chỉ khoảng 0,1% giao dịch được gán nhãn rửa tiền (class imbalance). Thứ hai, một giao dịch đơn lẻ hầu như không mang tín hiệu; dấu hiệu nằm ở *bối cảnh* như lịch sử tài khoản, nhịp độ giao dịch và mối quan hệ giữa các tài khoản. Thứ ba, dữ liệu có thứ tự thời gian, nên rất dễ vô tình để model "nhìn thấy tương lai" khi feature engineering (temporal leakage), dẫn tới kết quả lạc quan giả tạo.

Có hai hướng phổ biến để cải thiện detector. Hướng thứ nhất là *data augmentation* cho positive class bằng oversampling, SMOTE [6], generative model như CTGAN [18], hoặc gần đây là LLM [5, 15]. Hướng thứ hai là *feature engineering*: mô tả hành vi theo thời gian của tài khoản và quan hệ giữa các tài khoản [4, 8]. Bài báo này so sánh hai hướng trên trong cùng một quy trình: cùng temporal split, cùng classifier XGBoost [7] với hyperparameter cố định, cùng cách chọn threshold trên validation set và ba seed. Các đóng góp chính gồm:

- Một feature set gồm 63 behavioral feature được tính *nghiêm ngặt theo thời gian*: chỉ dùng giao dịch có thời điểm nhỏ hơn thời điểm dự đoán, các giao dịch cùng phút dùng chung một snapshot lịch sử, và các tổng tiền được tách theo currency.
- Một ablation study có kiểm soát gồm năm cấu hình định trước, cho thấy AP tăng từ 0,171 lên 0,684 và mọi bước bổ sung đều cải thiện AP trong cả ba seed.
- Evaluation bốn phương pháp data augmentation, gồm hai biến thể sinh dữ liệu bằng LLM, kèm chẩn đoán chất lượng synthetic data. Không phương pháp nào cải thiện rõ rệt; synthetic data của CTGAN và LLM gần như bị tách biệt hoàn toàn khỏi dữ liệu thật.
- Phân tích tính hợp lệ của evaluation: time policy, distribution shift từ ngày 11/09/2022 và việc tái sử dụng test set, cùng quy trình xác minh kết quả có thể tái lập (reproducible).

2 CÔNG TRÌNH LIÊN QUAN

Dataset và benchmark. Do dữ liệu ngân hàng thật không thể công bố, nghiên cứu học thuật chủ yếu dùng dữ liệu công khai như transaction graph Bitcoin Elliptic [17] hoặc dữ liệu mô phỏng. Altman và cộng sự [3] công bố trình sinh AMLworld dựa trên agent-based simulation và sáu dataset giao dịch ngân hàng tổng hợp có nhãn đầy đủ [2]; HI-Small là dataset nhỏ nhất với tỷ lệ giao dịch rửa tiền cao hơn (HI: higher illicit ratio).

Graph feature và GNN. Graph Feature Preprocessor (GFP) [4], thuộc thư viện Snap ML [9], trích xuất theo thời gian thực các pattern fan-in/fan-out, scatter-gather và cycle, cùng vertex statistics trong time window, rồi đưa vào gradient boosting model; trên HI-Small cách làm này đạt minority-class F1 khoảng 0,63–0,65 và vượt các Graph Neural Network (GNN) tiêu chuẩn. Multi-GNN [11] mở

Bảng 1: Temporal split của dữ liệu.

Tập	Giao dịch	Positive	Tỷ lệ	Khoảng thời gian
Train	3.046.861	2.297	0,075%	01/09 – 06/09 13:35
Validation	1.015.602	1.082	0,107%	06/09 13:36 – 08/09 16:11
Test	1.015.882	1.798	0,177%	08/09 16:12 – 18/09

rộng GNN cho directed multigraph. Deprez và cộng sự [8] tổng quan 97 công trình và cho thấy thông tin network cải thiện khả năng dự đoán. Các công trình gần đây tập trung vào tốc độ pattern mining [19] hoặc biểu diễn quasi-temporal graph [16]. Ngược lại, Effendi và Chattopadhyay [10] ghi nhận XGBoost có thể không cần graph feature trong một số cấu hình dữ liệu. Bài báo này không tái hiện GFP mà tập trung vào các thống kê hành vi và quan hệ cục bộ có thể giải thích trực tiếp.

Data augmentation và LLM. SMOTE [6] nội suy giữa các minority sample; CTGAN [18] học phân phối tabular data bằng conditional GAN. LLM được dùng để sinh tabular data [5], kết hợp với data curation trong low-data regime [15], hoặc để tự động đề xuất feature [1, 13]. Chúng tôi đánh giá khả năng sinh giao dịch rửa tiền bằng LLM trong feature space cho bài toán cực kỳ mất cân bằng.

3 DỮ LIỆU VÀ BÀI TOÁN

Dataset. Chúng tôi dùng tệp `HI-Small_Trans.csv` của IBM AML [2] gồm 5.078.345 giao dịch trong khoảng 01–18/09/2022, trong đó 5.177 giao dịch (0,102%) được gán nhãn rửa tiền. Mỗi giao dịch có timestamp (độ phân giải phút), ngân hàng và tài khoản của sender/receiver, số tiền và currency hai phía, payment format và nhãn. Tệp được đối chiếu bằng SHA-256 hash giữa môi trường cục bộ và Kaggle. Tài khoản được định danh bằng cặp ngân hàng–mã tài khoản; định danh chỉ dùng để tra cứu lịch sử, không đưa vào model.

Bài toán. Mỗi giao dịch là một sample. Model trả về suspicion score để xếp hạng; quyết định nhị phân dùng threshold chọn trên validation set. Score không được calibrate thành xác suất rủi ro.

Temporal split. Dữ liệu được sắp xếp theo timestamp và chia xấp xỉ 60/20/20; điểm cắt được dịch về đầu nhóm giao dịch cùng phút để một phút không bị tách sang hai tập (Bảng 1). Không shuffle dữ liệu; nhãn của validation và test set không tham gia feature engineering hay training.

4 PHƯƠNG PHÁP

4.1 Time policy

Gọi t là timestamp của giao dịch cần dự đoán. Tập lịch sử được phép quan sát là

$$H(t) = \{\, j : t_j < t \,\}. \tag{1}$$

Vì dữ liệu chỉ chính xác đến phút và thứ tự thật trong cùng phút là không biết, mọi giao dịch cùng timestamp dùng chung một snapshot lịch sử; lịch sử chỉ được cập nhật sau khi cả nhóm đã được truy vấn. Nhờ vậy feature không phụ thuộc thứ tự dòng trong tệp. Self-transfer tạo một sự kiện gửi và một sự kiện nhận, và sự kiện gửi của chính giao dịch không trở thành lịch sử của phía nhận. Time window độ dài W được định nghĩa là $[t - W, t)$. Các giao dịch không nhãn đã xảy ra trong validation và test set được phép bổ sung lịch sử cho giao dịch đến sau, tương ứng với việc quan sát luồng giao dịch theo thời gian.

4.2 Behavioral feature

Feature set gồm bốn feature group, tổng cộng 63 cột:

- **Transaction (11):** log số tiền gửi/nhận, giờ, thứ, payment format, currency hai phía, cùng ngân hàng, self-transfer, đổi currency, số tiền tròn trăm.
- **History (17):** với mỗi tài khoản sender và receiver: số giao dịch trước đó, số lượt gửi và nhận, trung bình log số tiền gửi và nhận, thời gian từ giao dịch gần nhất, số giao dịch cùng ngày tổng và theo hướng; thêm số giao dịch trước đó của cặp sender→receiver.
- **Activity (20):** với time window 1 giờ và 24 giờ, số lượt và log tổng tiền theo hướng của mỗi tài khoản, cùng độ lệch giữa log số tiền hiện tại và trung bình log lịch sử cùng hướng. Các tổng tiền và độ lệch được tính riêng theo tài khoản *và currency*, không cộng các currency khác nhau khi không có tỷ giá. Sliding sum dùng Neumaier compensated summation để không để lại sai số khi các khoản tiền chênh lệch rất lớn rời khỏi window.
- **Relationship (15):** số counterparty duy nhất theo hướng và window, số giao dịch lịch sử của cặp đảo chiều, tuổi và độ gần (recency) của quan hệ sender→receiver, số giao dịch của cặp trong window, và counterparty share trong 24 giờ (số giao dịch A→B chia số lượt gửi của A).

Khi không có lịch sử, số đếm và tổng bằng 0, còn trung bình và khoảng thời gian để NaN cho XGBoost tự xử lý. Năm cấu hình được xác định trước khi chạy: F0 = Transaction; F1 = F0 + History; F2 = F1 + Activity; F3 = F1 + Relationship; F4 = F1 + Activity + Relationship. Hiệu số F1−F0 đo tác động của History; F2−F1 và F3−F1 đo lợi ích của từng group khi đã có History; F4−F2 và F4−F3 đo phần bổ sung của group còn lại. Feature được tính bằng các linear scan theo tài khoản, tăng tốc bằng Numba.

4.3 Data augmentation

Các phương pháp augmentation chỉ bổ sung giao dịch rửa tiền tổng hợp vào train set; validation và test set luôn là dữ liệu thật. Số synthetic sample bằng 0,5 lần số positive sample của train set (1.148 sample mỗi lượt). Chúng tôi so sánh: **ER** random oversampling positive sample; **E1** SMOTENC trên feature đã chuẩn hóa, categorical feature lấy mode của các nearest neighbor; **E2** CTGAN 300 epoch chỉ học trên positive sample; **E3a/E3b** một LLM thương mại qua OpenAI API sinh giao dịch rửa tiền dạng JSON từ các example thật, thống kê cột và các ràng buộc logic giữa các cột, trong đó E3b bổ sung mô tả các laundering typology của AMLworld vào prompt. Output của LLM được validate, loại duplicate và loại các dòng sao chép nguyên văn dữ liệu thật; chi phí API được giới hạn bằng một budget ledger. Chất lượng synthetic data được đo bằng thống kê Kolmogorov–Smirnov (KS) trung bình theo cột so với positive sample thật, và bằng AUC của một XGBoost discriminator phân biệt thật/giả (*discriminator AUC*; 0,5 nghĩa là không phân biệt được).

Thí nghiệm augmentation được thực hiện trước feature study, trên pipeline 28 feature tương ứng F1 nhưng xử lý các giao dịch cùng phút theo thứ tự dòng ổn định trong tệp. Vì khác protocol,

chúng tôi chỉ so sánh các phương pháp augmentation với nhau, không so sánh con số tuyệt đối với F0–F4.

4.4 Model và evaluation

Mọi cấu hình dùng XGBoost với tối đa 1.000 cây, learning rate 0,05, max depth 8, subsample và colsample_bytree 0,8, min child weight 1, `hist` tree method trên GPU, early stopping sau 100 vòng theo AUC-PR trên validation set. Không có hyperparameter tuning riêng cho từng cấu hình và không resampling tỷ lệ lớp. Threshold tối đa F1 được chọn trên validation set của từng lượt chạy rồi áp dụng nguyên cho test set.

Metric chính là Average Precision (AP), tính bằng hàm average precision của scikit-learn. Ngoài ra chúng tôi báo cáo F1 tại threshold và Precision@1000/Recall@1000: tỷ lệ giao dịch rửa tiền trong 1.000 alert có score cao nhất trên toàn test set, và tỷ lệ giao dịch rửa tiền của test set nằm trong danh sách đó. Accuracy không được dùng vì positive class rất hiếm. Mỗi cấu hình chạy ba seed (0, 1, 2); bảng trình bày mean ± sample standard deviation (SD), và các so sánh dùng paired difference theo cùng seed. SD này phản ánh biến động training trên cùng test set, không phải confidence interval trên quần thể giao dịch mới.

4.5 Verification và reproducibility

Pipeline có 43 regression test: biên thời gian và window, self-transfer, currency, tính bất biến khi đổi thứ tự các dòng cùng timestamp, tính độc lập với nhãn và tương lai, và đối chiếu với cách tính trực tiếp trên mẫu nhỏ. Sau khi chạy, 30 prediction file của 15 lượt được kiểm tra lại về nhãn, thứ tự, AP, metric tại threshold và việc threshold được chọn trên validation set. Một manifest ghi hash của dữ liệu và source code, phiên bản thư viện, danh sách cột và thông tin split. Các lượt chạy được thực hiện trên Kaggle notebook riêng tư với hai GPU Tesla T4, NumPy 2.2.6, pandas 2.3.3, scikit-learn 1.7.2, XGBoost 3.1.1 và Numba 0.61.2.

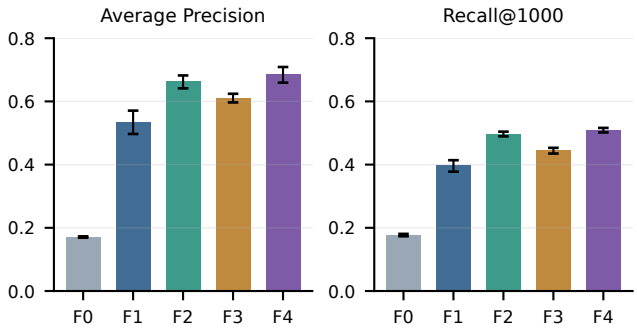
5 KẾT QUẢ THỰC NGHIỆM

5.1 Ablation study theo feature group

Bảng 2 cho thấy chỉ dùng thuộc tính của từng giao dịch (F0) cho AP 0,171. Bổ sung History (F1) tạo bước nhảy lớn nhất, lên 0,534. Khi đã có History, Activity group (F2, 0,662) đóng góp nhiều hơn Relationship group (F3, 0,610), và kết hợp cả hai (F4) đạt AP cao nhất, 0,684. Thứ tự các cấu hình giống nhau trên validation và test set. Bảng 3 cho thấy mọi bước bổ sung đều cải thiện AP trong cả ba seed, kể cả F4 so với F2: Relationship group vẫn mang thông tin bổ sung khi đã có Activity group. Ba seed chỉ đủ mô tả tính nhất quán của các lượt chạy này, chưa đủ để khẳng định statistical significance.

5.2 Ý nghĩa theo alert budget

Test set có 1.798 giao dịch rửa tiền. Trong 1.000 alert có score cao nhất, F1 tìm được trung bình khoảng 712 giao dịch rửa tiền, còn F4 tìm được 915; số false positive giảm tương ứng trong khi khối lượng công việc của chuyên viên vẫn là 1.000 alert. Tuy vậy, recall 0,509 cũng có nghĩa là gần một nửa số giao dịch rửa tiền nằm ngoài danh sách. Alert budget 1.000 alert cho toàn test set là một giả định



Hình 1: AP và Recall@1000 của năm cấu hình feature; error bar là SD qua ba seed trên cùng test set.

thực nghiệm; hệ thống thật có thể cần giới hạn theo ngày hoặc theo năng lực xử lý của bộ phận điều tra.

5.3 Feature importance

Bảng 4 cho thấy các feature quan trọng nhất kết hợp thuộc tính hiện tại với bối cảnh tài khoản: số lượt nhận trước đó của sender, thời gian từ giao dịch gần nhất của receiver, độ lệch số tiền so với lịch sử cùng currency, payment format và số lần cặp tài khoản đã giao dịch. Điều này phù hợp với trực giác nghiệp vụ: tài khoản vừa nhận tiền rồi chuyển đi với số tiền bất thường so với thói quen là dấu hiệu của money mule. Tuy nhiên, gain importance của cây bị ảnh hưởng bởi tương quan giữa các cột, nên không được diễn giải như tác động nhân quả và không thay thế ablation study theo group ở trên.

5.4 Data augmentation

Bảng 5 cho thấy không phương pháp augmentation nào cải thiện rõ rệt so với không augmentation (AP 0,670). SMOTENC cho AP 0,673, paired difference theo cùng seed chỉ 0,0026 và nằm trong biến động giữa các seed. Random oversampling giảm nhẹ (ΔAP = −0,0077), CTGAN giảm −0,0221, còn hai biến thể LLM giảm mạnh nhất (−0,0611 và −0,0732).

Cột discriminator AUC giải thích hiện tượng này. Sample lặp lại không phân biệt được với sample thật (0,502), SMOTENC ở mức 0,647, trong khi CTGAN (0,999) và LLM (0,983 và 0,996) gần như bị tách biệt hoàn toàn. Synthetic sample vẫn mang nhãn positive, nên model học thêm những vùng không tồn tại trong dữ liệu thật. Với LLM, precision tại threshold tăng nhưng recall giảm mạnh: model trở nên "thận trọng" hơn và bỏ sót nhiều giao dịch rửa tiền hơn. Đáng chú ý, bổ sung domain knowledge về các laundering typology vào prompt (E3b) không cải thiện mà còn làm kết quả kém ổn định hơn giữa các seed (SD của F1 lớn). Với dữ liệu giao dịch, mỗi giao dịch rửa tiền là một phần của chuỗi có cấu trúc thời gian và quan hệ; sinh từng dòng độc lập trong feature space khó tái tạo được các ràng buộc này. Đây là lý do thực tế để chúng tôi chuyển trọng tâm sang feature engineering.

5.5 Distribution shift theo thời gian

Thống kê theo ngày cho thấy từ 11/09/2022, lưu lượng giao dịch giảm mạnh trong khi tỷ lệ positive label tăng vọt (Hình 2): ngày

Bảng 2: Ablation study theo feature group (mean ± SD qua ba seed). AP được báo cáo trên test và validation set; các metric còn lại trên test set.

Cấu hình	Số feature	AP (test)	AP (validation)	F1	Precision@1000	Recall@1000
F0 Transaction	11	0,171 ± 0,002	0,064 ± 0,001	0,246 ± 0,016	0,318 ± 0,007	0,177 ± 0,004
F1 +History	28	0,534 ± 0,037	0,477 ± 0,026	0,534 ± 0,028	0,712 ± 0,033	0,396 ± 0,018
F2 +Activity	48	0,662 ± 0,020	0,583 ± 0,014	0,664 ± 0,016	0,893 ± 0,013	0,497 ± 0,007
F3 +Relationship	43	0,610 ± 0,014	0,521 ± 0,026	0,589 ± 0,026	0,798 ± 0,016	0,444 ± 0,009
F4 Combined	63	**0,684 ± 0,025**	**0,592 ± 0,023**	**0,685 ± 0,026**	**0,915 ± 0,013**	**0,509 ± 0,007**

Bảng 3: Paired difference của AP trên test set theo cùng seed.

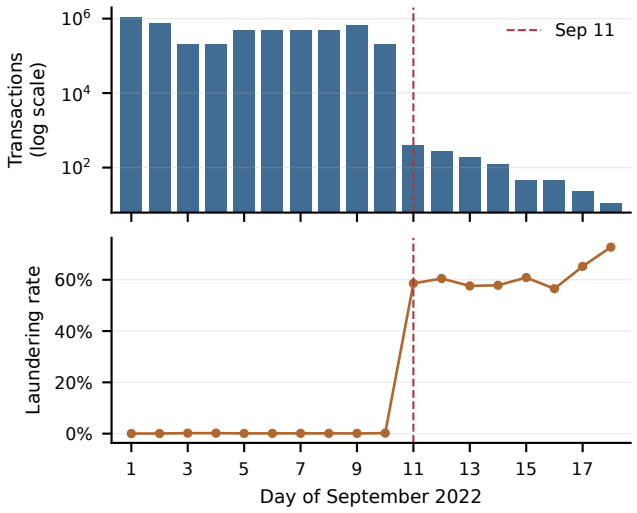
So sánh	Mean ΔAP	SD	Số seed tăng
F1 − F0	+0,3631	0,0371	3/3
F2 − F1	+0,1278	0,0165	3/3
F3 − F1	+0,0765	0,0233	3/3
F4 − F1	+0,1502	0,0122	3/3
F4 − F2	+0,0224	0,0043	3/3
F4 − F3	+0,0737	0,0112	3/3

Bảng 4: Mười feature có tỷ trọng total gain trung bình cao nhất trong F4 (ba seed).

#	Feature	Group	Gain (%)
1	Số lượt nhận trước đó của sender	History	7,74
2	Thời gian từ giao dịch gần nhất của receiver	History	7,05
3	Độ lệch số tiền so với lịch sử gửi (cùng currency)	Activity	6,35
4	Payment format	Transaction	5,27
5	Giờ trong ngày	Transaction	4,77
6	Số giao dịch trước đó của cặp sender→receiver	History	4,64
7	Độ lệch số tiền so với lịch sử nhận của sender	Activity	4,29
8	Độ lệch số tiền so với lịch sử nhận của receiver	Activity	3,71
9	Log tổng tiền sender đã nhận trong 24 giờ	Activity	3,70
10	Trung bình log số tiền sender đã nhận	History	3,51

10/09 có 208.325 giao dịch và 442 positive label, ngày 11/09 chỉ có 396 giao dịch nhưng 232 positive label. Trong test set, phần trước 11/09 có 1.014.774 giao dịch với 1.143 positive label (0,113%), còn phần từ 11/09 chỉ có 1.108 giao dịch nhưng 655 positive label (59,1%). Nguyên nhân chưa được xác minh từ cơ chế sinh dữ liệu. Đây là phát hiện post-hoc, nên chúng tôi không loại phần này khỏi evaluation chính và không training lại, mà tách các prediction cố định thành hai phần để chẩn đoán (Bảng 6).

Trên phần trước 11/09, F4 vẫn vượt F1 (AP 0,528 so với 0,333), nên lợi ích của feature không chỉ đến từ phần cuối bất thường. Ở phần cuối, chỉ Transaction feature (F0) đã đạt AP 0,973 và F4 không vượt F0. Vì AP phụ thuộc tỷ lệ nhãn, chúng tôi chỉ so sánh các cấu hình trong cùng một phần, không so sánh AP giữa hai phần để kết luận phần nào dễ hơn.



Hình 2: Số giao dịch (log scale) và tỷ lệ positive label theo ngày trong HI-Small; đường đứt nét đánh dấu 11/09.

5.6 Chi phí tính toán

Trên Kaggle, tạo toàn bộ feature table (gồm đọc dữ liệu và biên dịch JIT) mất khoảng 35,0 giây và feature table chiếm khoảng 1,33 GB. Training 15 model mất 620,2 giây; toàn bộ lượt chạy, gồm evaluation và ghi tệp, mất 733,3 giây. Các con số mô tả một lượt chạy trên một môi trường cụ thể; chúng tôi chưa đo latency cập nhật feature theo từng giao dịch trong một online service.

6 THẢO LUẬN

Ý nghĩa đối với an toàn hệ thống thông tin. Hệ thống transaction monitoring là một thành phần phòng thủ; chất lượng của nó được đo bằng số giao dịch rửa tiền tìm được trong alert budget mà bộ phận điều tra xử lý được. Kết quả cho thấy feature engineering quyết định hiệu quả nhiều hơn việc bổ sung synthetic data, và behavioral feature còn có lợi thế giải thích được (explainable) bằng ngôn ngữ nghiệp vụ, điều cần thiết khi alert phải được chuyên viên xem xét. Mặt khác, một biểu diễn dựa trên hành vi cũng tạo

Bảng 5: Data augmentation cho train set (protocol của pipeline trước, 28 feature; ba seed). KS và discriminator AUC đo khoảng cách giữa synthetic sample và positive sample thật; discriminator AUC càng gần 0,5 thì synthetic data càng giống thật.

Phương pháp	AP	F1	Precision@1000	Mean KS	Discriminator AUC
E0 No augmentation	0,670 ± 0,008	0,673 ± 0,010	0,902	–	–
ER Random oversampling	0,662 ± 0,010	0,664 ± 0,003	0,894	0,019	0,502
E1 SMOTENC	0,673 ± 0,014	0,674 ± 0,009	0,899	0,047	0,647
E2 CTGAN	0,648 ± 0,014	0,625 ± 0,016	0,883	0,221	0,999
E3a LLM, basic prompt	0,609 ± 0,015	0,588 ± 0,018	0,854	0,126	0,983
E3b LLM, AML-aware prompt	0,597 ± 0,051	0,493 ± 0,181	0,838	0,139	0,996

Bảng 6: AP trên hai phần của test set, tách tại 11/09/2022 (post-hoc diagnostic, cùng các model).

Cấu hình	Trước 11/09	Từ 11/09
F0	0,071 ± 0,000	0,973 ± 0,000
F1	0,333 ± 0,042	0,962 ± 0,004
F2	0,506 ± 0,022	0,958 ± 0,005
F3	0,413 ± 0,022	0,962 ± 0,004
F4	0,528 ± 0,028	0,961 ± 0,005

ra attack surface: kẻ rửa tiền có thể chủ động chia nhỏ giao dịch (structuring), giãn thời gian hoặc thêm money mule để làm sai lệch các thống kê theo window và quan hệ (evasion attack). Trong triển khai, hệ thống còn cần access control cho dữ liệu, bảo vệ API key và kết quả alert; source code công bố của chúng tôi không chứa API key, dữ liệu thô hay prediction của từng giao dịch.

Temporal leakage là một lỗ hổng phương pháp. Một score cao mất ý nghĩa nếu feature dùng thông tin tương lai, nhãn của tập evaluation, hoặc phụ thuộc vào thứ tự dòng tùy ý của tệp. Pipeline augmentation trước dùng 28 feature tương ứng F1 nhưng xử lý giao dịch cùng phút theo thứ tự dòng, và đạt AP 0,670 khi không augmentation; F1 với time policy nghiêm ngặt chỉ đạt 0,534. Hai pipeline còn khác nhau ở một số chi tiết cài đặt, nên đây không phải phép so sánh có kiểm soát. Tuy nhiên, khoảng cách lớn này gợi ý rằng thông tin về các giao dịch cùng phút và thứ tự của chúng trong tệp có thể làm score tăng đáng kể. Vì vậy, khi so sánh các feature set hoặc so sánh với công trình khác, time policy phải được cố định và công bố rõ, giống như việc cố định model và temporal split. Cũng vì lý do này, F1 của F4 (0,685) không nên được so sánh trực tiếp với các con số đã công bố trên HI-Small [4, 11]: các công trình đó dùng điểm cắt train/test khác (ví dụ Multi-GNN cắt theo nguyên ngày), threshold cố định thay vì chọn trên validation, và cách xử lý thời gian khác.

Giới hạn. (i) Dữ liệu là mô phỏng, nhãn do trình sinh tạo ra, không có KYC, số dư hay xác minh nguồn tiền thật. (ii) Test set HI-Small đã được xem trong thí nghiệm augmentation trước, nên dù năm cấu hình được định trước, kết quả vẫn mang tính exploratory. (iii) Ba seed chỉ đo biến động training, không chứng minh statistical significance trên dữ liệu độc lập. (iv) Hyperparameter cố định, nên kết quả là tác động của feature dưới một training budget, không phải hiệu năng tối đa; một số lượt chạm hoặc gần giới hạn 1.000 cây. (v) Trung bình log số tiền trong History group vẫn gộp các currency. (vi) Relationship group chỉ gồm thống kê cục bộ, chưa phát hiện cycle hay chuỗi nhiều bước (multi-hop). (vii) Thí nghiệm augmentation dùng protocol khác. (viii) Phần cuối test set có distribution shift bất thường. (ix) Kết quả chưa được kiểm chứng trên các dataset AMLworld khác hay dữ liệu ngân hàng thật.

7 KẾT LUẬN

Trên dataset IBM AML HI-Small, feature engineering hành vi mang lại lợi ích lớn và nhất quán, trong khi bổ sung synthetic data thì không. Với XGBoost cố định, bổ sung History, Activity và Relationship feature nâng AP từ 0,171 lên 0,684; trong 1.000 alert có score cao nhất, cấu hình đầy đủ đạt precision 91,50% và recall 50,89%. Activity group đóng góp nhiều hơn Relationship group khi bổ sung riêng, và Relationship group vẫn cải thiện thêm khi kết hợp. Random oversampling, SMOTENC, CTGAN và hai biến thể LLM đều không cải thiện rõ rệt; synthetic data do CTGAN và LLM sinh ra gần như bị phân biệt hoàn toàn với dữ liệu thật. Kết quả trên phần test trước 11/09 duy trì lợi ích của feature, đồng thời distribution shift ở phần cuối nhắc rằng kết luận có thể không đồng nhất ở mọi giai đoạn của dữ liệu.

Các hướng phát triển gồm: so sánh với multi-hop graph pattern feature như GFP dưới cùng time policy; phân tích kết quả theo từng laundering typology; đánh giá robustness của model trước các evasion strategy như structuring hay dùng money mule; và kiểm chứng trên các dataset AMLworld khác với một held-out test set hoàn toàn mới.

Reproducibility. Source code, cấu hình, test và kết quả từng lượt chạy được công bố tại https://github.com/Chung10102004/atbmtt. Dữ liệu thô và prediction của từng giao dịch không được đưa vào repository.

TÀI LIỆU

[1] Nikhil Abhyankar, Parshin Shojaee, and Chandan K. Reddy. 2025. LLM-FE: Automated Feature Engineering for Tabular Data with LLMs as Evolutionary Optimizers. arXiv:2503.14434

[2] Erik Altman. 2023. IBM Transactions for Anti Money Laundering (AML). https://www.kaggle.com/datasets/ealtman2019/ibm-transactions-for-anti-money-laundering-aml. File HI-Small_Trans.csv.

[3] Erik Altman, Jovan Blanuša, Luc von Niederäusern, Béni Egressy, Andreea Anghel, and Kubilay Atasu. 2023. Realistic Synthetic Financial Transactions for Anti-Money Laundering Models. In *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track.*

[4] Jovan Blanuša, Maximo Cravero Baraja, Andreea Anghel, Luc von Niederäusern, Erik Altman, Haris Pozidis, and Kubilay Atasu. 2024. Graph Feature Preprocessor: Real-time Subgraph-based Feature Extraction for Financial Crime Detection. In *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF)*. https://doi.org/10.1145/3677052.3698674 arXiv:2402.08593.

[5] Vadim Borisov, Kathrin Seßler, Tobias Leemann, Martin Pawelczyk, and Gjergji Kasneci. 2023. Language Models are Realistic Tabular Data Generators. In *International Conference on Learning Representations (ICLR)*.

[6] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. 2002. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research* 16 (2002), 321–357.

[7] Tianqi Chen and Carlos Guestrin. 2016. XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 785–794. https://doi.org/10.1145/2939672.2939785

[8] Bruno Deprez, Toon Vanderschueren, Bart Baesens, Tim Verdonck, and Wouter Verbeke. 2024. Network Analytics for Anti-Money Laundering – A Systematic Literature Review and Experimental Evaluation. *INFORMS Journal on Data Science* (2024). https://doi.org/10.1287/ijds.2024.0042 arXiv:2405.19383.

[9] Celestine Dünner, Thomas Parnell, Dimitrios Sarigiannis, Nikolas Ioannou, Andreea Anghel, Gummadi Ravi, Madhusudanan Kandasamy, and Haralampos Pozidis. 2018. Snap ML: A Hierarchical Framework for Machine Learning. In *Advances in Neural Information Processing Systems (NeurIPS)*.

[10] Fabrianne Effendi and Anupam Chattopadhyay. 2024. Privacy-Preserving Graph-Based Machine Learning with Fully Homomorphic Encryption for Collaborative Anti-Money Laundering. arXiv:2411.02926

[11] Béni Egressy, Luc von Niederäusern, Jovan Blanuša, Erik Altman, Roger Wattenhofer, and Kubilay Atasu. 2024. Provably Powerful Graph Neural Networks for Directed Multigraphs. In *Proceedings of the AAAI Conference on Artificial Intelligence*.

[12] Financial Action Task Force. 2012. International Standards on Combating Money Laundering and the Financing of Terrorism & Proliferation – The FATF Recommendations. https://www.fatf-gafi.org. Updated periodically.

[13] Noah Hollmann, Samuel Müller, and Frank Hutter. 2023. Large Language Models for Automated Data Science: Introducing CAAFE for Context-Aware Automated Feature Engineering. In *Advances in Neural Information Processing Systems (NeurIPS)*.

[14] Quốc hội nước Cộng hòa Xã hội Chủ nghĩa Việt Nam. 2022. Luật Phòng, chống rửa tiền, số 14/2022/QH15.

[15] Nabeel Seedat, Nicolas Huynh, Boris van Breugel, and Mihaela van der Schaar. 2024. Curated LLM: Synergy of LLMs and Data Curation for Tabular Augmentation in Low-Data Regimes. In *International Conference on Machine Learning (ICML)*.

[16] Haseeb Tariq and Marwan Hassani. 2026. Extracting Money Laundering Transactions from Quasi-Temporal Graph Representation. arXiv:2604.02899

[17] Mark Weber, Giacomo Domeniconi, Jie Chen, Daniel Karl I. Weidele, Claudio Bellei, Tom Robinson, and Charles E. Leiserson. 2019. Anti-Money Laundering in Bitcoin: Experimenting with Graph Convolutional Networks for Financial Forensics. In *KDD Workshop on Anomaly Detection in Finance*.

[18] Lei Xu, Maria Skoularidou, Alfredo Cuesta-Infante, and Kalyan Veeramachaneni. 2019. Modeling Tabular Data using Conditional GAN. In *Advances in Neural Information Processing Systems (NeurIPS)*.

[19] Haojie Ye, Arjun Laxman, Yichao Yuan, Krisztian Flautner, and Nishil Talati. 2026. BlazingAML: High-Throughput Anti-Money Laundering (AML) via Multi-Stage Graph Mining. arXiv:2604.12241